
Mesure et validation du risque d'un portefeuille

Comment mesurer et valider le risque de marché d'un portefeuille, et quelle méthode de Value-at-Risk fournit les prévisions les plus fiables ?

Audoin Sabrié

Septembre 2026

Table des matières

1	Introduction	3
2	Construction du portefeuille et préparation des données	3
2.1	Composition du portefeuille	3
2.2	Données	4
2.3	Passage des rendements aux pertes	4
3	Définition et protocole d'estimation de la VaR	5
3.1	Définition	5
3.2	Fenêtre glissante	6
3.3	Absence de biais d'anticipation	6
4	Méthodes d'estimation de la VaR	7
4.1	Méthode historique	7
4.2	Méthode paramétrique normale	7
4.3	Simulation de Monte Carlo	8
4.4	Estimation non paramétrique par noyau	9
4.4.1	Estimateur de densité	9
4.4.2	Estimateur de la fonction de répartition	9
4.4.3	Choix du paramètre de lissage	9
5	Backtesting des prévisions de VaR	10
5.1	Indicateur d'exception	10
5.2	Test de couverture inconditionnelle de Kupiec	11
5.3	Test d'indépendance de Christoffersen	12
5.4	Test de couverture conditionnelle	13
6	Résultats du backtesting	13
6.1	VaR historique	13
6.2	VaR paramétrique normale	14
6.3	Simulation de Monte Carlo	15
6.4	VaR obtenue par KDE	15
7	Comparaison des méthodes	16
8	Limites de l'étude	16

8.1	Taille effective de la queue	16
8.2	Choix de la fenêtre	17
8.3	Hypothèse de normalité	17
8.4	Indépendance temporelle des rendements	17
8.5	Limites des tests de backtesting	17
9	Conclusion	17

1 Introduction

La mesure du risque de marché constitue une problématique centrale en gestion des risques financiers. Elle consiste notamment à quantifier les pertes susceptibles d'être subies par un portefeuille sur un horizon donné, sous un niveau de confiance fixé. Parmi les indicateurs utilisés à cette fin, la Value-at-Risk (VaR) occupe une place importante : elle fournit un quantile de la distribution des pertes et permet ainsi de déterminer un niveau de perte qui ne devrait être dépassé qu'avec une faible probabilité.

Cependant, une VaR ne peut pas être évaluée uniquement à partir de sa valeur estimée. Une méthode peut produire une estimation apparemment raisonnable tout en sous-estimant systématiquement certains épisodes de marché, ou au contraire produire une mesure excessivement prudente. Il est donc nécessaire de confronter les prévisions aux pertes effectivement observées. Cette étape de validation, appelée *backtesting*, permet notamment de vérifier la fréquence des dépassements de VaR ainsi que leur éventuelle concentration dans le temps.

L'objectif de ce travail est donc double. Il s'agit d'abord de construire plusieurs estimations de la VaR d'un portefeuille diversifié à partir de données historiques. Quatre approches sont étudiées : la méthode historique, une approche paramétrique fondée sur une loi normale, une simulation de Monte Carlo et une estimation non paramétrique de la densité par noyau (*Kernel Density Estimation*, KDE). Il s'agit ensuite de comparer leur capacité à prévoir les pertes extrêmes au moyen de tests statistiques de couverture.

La question étudiée est ainsi la suivante :

Comment mesurer et valider le risque de marché d'un portefeuille, et quelle méthode de Value-at-Risk fournit les prévisions les plus fiables ?

L'analyse porte sur un portefeuille équipondéré composé de cinq ETF représentant différentes classes d'actifs. Les estimations sont réalisées de manière dynamique à partir d'une fenêtre glissante de 750 observations quotidiennes. Les niveaux de confiance retenus sont de 95 % et 99 %. Les prévisions sont ensuite évaluées à l'aide des tests de couverture inconditionnelle de Kupiec, d'indépendance de Christoffersen et de couverture conditionnelle.

2 Construction du portefeuille et préparation des données

2.1 Composition du portefeuille

Le portefeuille étudié est constitué de cinq ETF :

Actif	Ticker	Poids
SPDR S&P 500 ETF Trust	SPY	20 %
iShares MSCI EAFE ETF	EFA	20 %
iShares 20+ Year Treasury Bond ETF	TLT	20 %
SPDR Gold Shares	GLD	20 %
Vanguard Real Estate ETF	VNQ	20 %

TABLE 1 – Composition du portefeuille

Le choix d'un portefeuille équipondéré permet de se concentrer sur la mesure du risque plutôt que sur une problématique d'optimisation des poids. Les cinq actifs ont par ailleurs des expositions économiques différentes : actions américaines, actions des pays développés hors États-Unis,

obligations souveraines américaines de maturité longue, or et immobilier coté. Cette diversification permet d'obtenir une distribution de rendement qui ne correspond pas au comportement d'un actif financier unique.

Le vecteur des poids est donc

$$w = \begin{pmatrix} 0.2 & 0.2 & 0.2 & 0.2 & 0.2 \end{pmatrix}^\top,$$

avec

$$\sum_{i=1}^5 w_i = 1.$$

2.2 Données

Les données proviennent de Yahoo Finance et correspondent aux cours de clôture ajustés des cinq ETF. La période étudiée s'étend du 2 janvier 2018 au 8 septembre 2026.

Les données disponibles contiennent 2182 observations de prix. Après calcul des rendements, l'échantillon comporte donc

$$T = 2181$$

observations quotidiennes.

Les cours ajustés sont utilisés afin de tenir compte des opérations susceptibles d'affecter la valeur économique détenue par l'investisseur, notamment les distributions. Les rendements simples sont ensuite calculés selon

$$R_{i,t} = \frac{P_{i,t}}{P_{i,t-1}} - 1,$$

où $P_{i,t}$ désigne le prix ajusté de l'actif i à la date t .

Le rendement du portefeuille est obtenu par agrégation des rendements individuels :

$$R_{p,t} = \sum_{i=1}^5 w_i R_{i,t}.$$

Dans le cadre d'un portefeuille à poids constants, cette expression fournit le rendement quotidien du portefeuille associé aux poids retenus.

2.3 Passage des rendements aux pertes

La VaR porte sur les pertes plutôt que sur les rendements. On définit donc la variable de perte quotidienne par

$$L_t = -R_{p,t}.$$

Ainsi, une valeur positive de L_t correspond à une perte tandis qu'une valeur négative correspond à un gain.

Cette convention est particulièrement pratique pour l'estimation de la VaR : un niveau de VaR élevé correspond directement à une perte potentiellement importante.

Les principales statistiques descriptives obtenues sur l'échantillon complet sont les suivantes :

Statistique	Valeur
Moyenne	-0.000372
Écart-type	0.007702
Asymétrie	0.5193
Kurtosis excédentaire	12.2995
VaR empirique à 95 %	0.01155
VaR empirique à 99 %	0.01935
Perte maximale	0.06811

TABLE 2 – Statistiques descriptives des pertes quotidiennes

Deux caractéristiques sont particulièrement importantes. Premièrement, la kurtosis excédentaire est fortement. Une loi normale possède une kurtosis excédentaire égale à zéro ; la valeur obtenue ici indique donc une distribution présentant des queues beaucoup plus épaisses que celles d'une loi normale.

Deuxièmement, l'asymétrie est positive. La distribution des pertes n'est donc pas parfaitement symétrique.

Ces éléments constituent un premier argument en faveur de méthodes capables de s'écarter d'une hypothèse de normalité stricte.

3 Définition et protocole d'estimation de la VaR

3.1 Définition

Soit L_{t+1} la perte du portefeuille à la date $t + 1$. Pour un niveau de confiance α , la Value-at-Risk est définie comme le quantile α de la distribution conditionnelle de la perte :

$$\text{VaR}_{\alpha,t} = F_{L_{t+1}|\mathcal{F}_t}^{-1}(\alpha),$$

où $F_{L_{t+1}|\mathcal{F}_t}$ désigne la fonction de répartition conditionnelle de la perte compte tenu de l'information disponible à la date t .

Par exemple, une VaR à 95 % égale à 1.2 % signifie que, selon le modèle retenu, la probabilité que la perte dépasse 1.2 % est de l'ordre de

$$1 - \alpha = 5 \, \%.$$

Dans ce travail, deux niveaux de confiance sont étudiés :

$$\alpha \in \{0.95, 0.99\}.$$

Le niveau de 95 % permet d'observer un nombre relativement important de dépassements, tandis que le niveau de 99 % permet de se concentrer davantage sur les pertes extrêmes.

3.2 Fenêtre glissante

Les estimations sont réalisées avec une fenêtre historique de

$$W = 750$$

observations quotidiennes.

À chaque date t , la VaR est donc estimée à partir des 750 pertes précédentes :

$$L_{t-W+1}, \dots, L_t.$$

La VaR produite correspond ensuite à la perte prévue pour la date $t + 1$.

Le choix d'une fenêtre glissante plutôt que d'une estimation sur l'ensemble de l'échantillon répond à une nécessité importante : le risque financier n'est pas nécessairement stationnaire dans le temps. Une fenêtre glissante permet de donner davantage de poids aux observations récentes et de faire évoluer les paramètres estimés au cours du temps.

Le choix de 750 observations constitue un compromis entre deux considérations. Une fenêtre trop courte permettrait une adaptation rapide aux changements de régime mais produirait des estimateurs plus bruités, notamment dans les queues de distribution. À l'inverse, une fenêtre trop longue stabiliserait davantage les estimations mais risquerait de conserver une influence importante d'observations anciennes correspondant à des conditions de marché différentes.

Une fenêtre de 750 jours représente environ trois années de séances boursières. Elle permet donc de disposer d'un échantillon suffisamment large pour estimer les quantiles extrêmes tout en conservant une certaine capacité d'adaptation aux évolutions du marché.

Ce choix doit cependant être considéré comme un choix de modélisation et non comme une valeur universellement optimale.

3.3 Absence de biais d'anticipation

Afin de respecter la chronologie de l'information disponible, l'estimation de la VaR utilisée pour prévoir L_{t+1} ne doit pas incorporer L_{t+1} lui-même.

Formellement, la prévision vérifie

$$\widehat{\text{VaR}}_{\alpha,t+1} = g(L_{t-W+1}, \dots, L_t),$$

et non

$$g(L_{t-W+1}, \dots, L_{t+1}).$$

En pratique, cela est obtenu par un décalage d'une période des séries de VaR. Cette précaution est essentielle : sans elle, une partie de l'information future serait utilisée pour construire la prévision, ce qui conduirait à un biais d'anticipation (*look-ahead bias*).

Après application de la fenêtre glissante, la période de backtesting contient

observations.

4 Méthodes d'estimation de la VaR

4.1 Méthode historique

La méthode historique constitue l'approche non paramétrique la plus directe.

À partir des W pertes observées dans la fenêtre glissante, on définit la fonction de répartition empirique :

$$\hat{F}_W(x) = \frac{1}{W} \sum_{j=1}^W \mathbf{1}_{\{L_j \leq x\}}.$$

Cette fonction constitue un estimateur naturel de la fonction de répartition inconnue F .

La VaR historique est alors définie comme le quantile empirique :

$$\widehat{\text{VaR}}_{\alpha}^H = \hat{F}_W^{-1}(\alpha).$$

Autrement dit, les pertes observées sont classées par ordre croissant et l'on sélectionne le quantile correspondant au niveau de confiance α .

L'intérêt principal de cette méthode est qu'elle ne nécessite aucune hypothèse paramétrique concernant la distribution des pertes. Les asymétries et les queues épaisses présentes dans les données sont donc directement conservées.

Son principal inconvénient est précisément son caractère discret. La méthode ne crée aucune observation intermédiaire : elle utilise directement les pertes historiques observées. Elle peut donc être sensible à la composition de la fenêtre et aux observations extrêmes qu'elle contient.

4.2 Méthode paramétrique normale

La deuxième méthode repose sur l'hypothèse que les pertes suivent une loi normale :

$$L_t \sim \mathcal{N}(\mu, \sigma^2).$$

Les paramètres inconnus sont estimés sur chaque fenêtre glissante par les estimateurs usuels :

$$\hat{\mu} = \frac{1}{W} \sum_{j=1}^W L_j,$$

et

$$\hat{\sigma}^2 = \frac{1}{W} \sum_{j=1}^W (L_j - \hat{\mu})^2.$$

La variance utilisée ici est l'estimateur de maximum de vraisemblance de la variance d'une loi normale. Le choix du dénominateur W , plutôt que $W - 1$, est donc cohérent avec cette interprétation.

Si z_α désigne le quantile α de la loi normale centrée réduite, alors

$$\widehat{\text{VaR}}_\alpha^N = \hat{\mu} + \hat{\sigma} z_\alpha.$$

Pour les deux niveaux considérés,

$$z_{0.95} \approx 1.645, \quad z_{0.99} \approx 2.326.$$

Cette approche est très simple et peu coûteuse numériquement. Elle permet également de disposer d'un modèle facilement interprétable.

En revanche, l'analyse descriptive précédente montre que l'hypothèse de normalité est restrictive pour les données étudiées. En particulier, une loi normale ne peut pas reproduire une kurtosis excédentaire aussi importante.

Le backtesting permettra donc de déterminer dans quelle mesure cette simplification affecte effectivement la qualité des prévisions de risque.

4.3 Simulation de Monte Carlo

La simulation de Monte Carlo consiste à générer artificiellement un grand nombre de réalisations de la distribution supposée des pertes, puis à estimer le quantile recherché à partir de ces simulations.

Dans notre cas, la distribution simulée repose sur les paramètres estimés précédemment :

$$L^{(m)} \sim \mathcal{N}(\hat{\mu}, \hat{\sigma}^2), \quad m = 1, \dots, M.$$

Les simulations produisent ainsi un échantillon

$$L^{(1)}, \dots, L^{(M)}.$$

La fonction de répartition empirique de l'échantillon simulé est

$$\hat{F}_M^{MC}(x) = \frac{1}{M} \sum_{m=1}^M \mathbf{1}_{\{L^{(m)} \leq x\}}.$$

La VaR de Monte Carlo est alors estimée par

$$\widehat{\text{VaR}}_\alpha^{MC} = \left(\hat{F}_M^{MC} \right)^{-1}(\alpha).$$

Le principe de Monte Carlo permet en théorie de traiter des modèles beaucoup plus complexes qu'une formule analytique directe. Il devient notamment utile lorsque la distribution du portefeuille résulte de transformations non linéaires ou de produits financiers complexes.

Dans notre application, toutefois, les simulations sont générées à partir d'une loi normale calibrée sur les données historiques. La méthode de Monte Carlo ne modifie donc pas l'hypothèse fondamentale sur la forme de la distribution. Elle introduit principalement une approximation numérique du quantile.

Cette distinction est importante pour interpréter les résultats : Monte Carlo n'est pas ici une méthode intrinsèquement plus flexible que l'approche normale.

4.4 Estimation non paramétrique par noyau

La quatrième méthode cherche à conserver la flexibilité d'une approche non paramétrique tout en évitant le caractère purement discret de la méthode historique.

4.4.1 Estimateur de densité

À partir des W pertes observées, l'estimateur de densité par noyau est défini par

$$\hat{f}_h(x) = \frac{1}{Wh} \sum_{j=1}^W K\left(\frac{x - L_j}{h}\right),$$

où K désigne une fonction noyau et $h > 0$ un paramètre de lissage appelé *bandwidth*.

Le noyau utilisé est le noyau gaussien :

$$K(u) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{u^2}{2}\right).$$

L'estimateur obtenu peut être interprété comme une somme de petites densités centrées sur chacune des observations historiques. Contrairement à la méthode historique, la distribution estimée est ainsi continue.

4.4.2 Estimateur de la fonction de répartition

La fonction de répartition associée à l'estimateur KDE est

$$\hat{F}_h(x) = \int_{-\infty}^x \hat{f}_h(u) du.$$

Avec un noyau gaussien, on obtient directement

$$\hat{F}_h(x) = \frac{1}{W} \sum_{j=1}^W \Phi\left(\frac{x - L_j}{h}\right),$$

où Φ désigne la fonction de répartition de la loi normale centrée réduite.

La VaR est alors obtenue comme le quantile de cette distribution estimée :

$$\widehat{\text{VaR}}_{\alpha}^{KDE} = \hat{F}_h^{-1}(\alpha).$$

Cette méthode reste non paramétrique : aucune forme fonctionnelle particulière n'est imposée à la distribution des pertes. Le noyau sert uniquement à lisser l'information observée.

4.4.3 Choix du paramètre de lissage

Le choix de h est central. Si h est trop faible, l'estimateur reproduit fortement les irrégularités de l'échantillon et risque de présenter une variance importante. Si h est trop grand, la distribution

est excessivement lissée et les caractéristiques importantes des données, notamment les queues, peuvent être atténuées.

Dans ce travail, le bandwidth est déterminé automatiquement à partir de la règle de Scott :

$$h = \hat{\sigma}W^{-1/5},$$

dans le cas unidimensionnel.

Plus généralement, la règle de Scott s'écrit

$$h = C\hat{\sigma}W^{-1/(d+4)},$$

où d représente la dimension des données. Ici, $d = 1$, d'où l'exposant $-1/5$.

Ce choix est justifié par plusieurs raisons. Premièrement, il fournit une règle objective et reproductible, sans calibrage manuel du bandwidth. Deuxièmement, le bandwidth diminue lorsque la taille de l'échantillon augmente, ce qui correspond au comportement attendu d'un estimateur non paramétrique : davantage d'observations permettent de représenter plus finement la distribution. Enfin, le bandwidth est proportionnel à l'écart-type empirique, ce qui adapte l'échelle du lissage à la dispersion des pertes.

La règle de Scott est toutefois conçue pour fournir un compromis global entre biais et variance de l'estimation de densité. Elle n'est pas spécifiquement optimisée pour les quantiles extrêmes à 99 %. Ce point est particulièrement important dans notre application : avec $W = 750$, une probabilité de dépassement de 1 % correspond à seulement

$$750 \times 0.01 = 7.5$$

observations extrêmes attendues dans une fenêtre.

L'estimation de la queue à 99 % reste donc intrinsèquement plus incertaine que celle du centre de la distribution. Le choix de Scott doit être compris comme une règle générale de lissage, et non comme une optimisation directe de la performance de VaR.

5 Backtesting des prévisions de VaR

5.1 Indicateur d'exception

Pour chaque date de backtesting, on définit l'indicateur

$$I_t = \mathbf{1}_{\{L_t > \widehat{\text{VaR}}_{\alpha,t}\}}.$$

Ainsi,

$$I_t = \begin{cases} 1 & \text{si la perte réalisée dépasse la VaR,} \\ 0 & \text{sinon.} \end{cases}$$

Une observation telle que $I_t = 1$ constitue une exception.

Sous un modèle correctement calibré, la probabilité théorique d'une exception est

$$p = 1 - \alpha.$$

Ainsi, on attend théoriquement 5 % d'exceptions à 95 % et 1 % à 99 %.

Le nombre total d'exceptions est

$$X = \sum_{t=1}^N I_t.$$

Le taux empirique d'exception est

$$\hat{p} = \frac{X}{N}.$$

5.2 Test de couverture inconditionnelle de Kupiec

Le test de Kupiec vérifie si la fréquence observée des exceptions est compatible avec la fréquence théorique $p = 1 - \alpha$.

Sous l'hypothèse nulle,

$$H_0 : p = 1 - \alpha.$$

La vraisemblance sous H_0 est

$$L_0 = (1 - p)^{N-X} p^X.$$

Sous l'hypothèse alternative, la probabilité d'exception est estimée par son maximum de vraisemblance :

$$\hat{p} = \frac{X}{N}.$$

La vraisemblance maximisée est alors

$$L_1 = (1 - \hat{p})^{N-X} \hat{p}^X.$$

La statistique du test est

$$\text{LR}_{UC} = -2 \log \left(\frac{L_0}{L_1} \right).$$

Sous H_0 , cette statistique suit asymptotiquement une loi du χ^2 à un degré de liberté :

$$\text{LR}_{UC} \stackrel{a}{\sim} \chi_1^2.$$

La p-value est donc calculée à partir de cette loi.

Avec un seuil de significativité de 5 %, une p-value inférieure à 0.05 conduit à rejeter l'hypothèse de couverture correcte.

5.3 Test d'indépendance de Christoffersen

Le test de Kupiec ne vérifie que la fréquence globale des exceptions. Il ne permet pas de détecter une éventuelle concentration temporelle des dépassements.

Le test de Christoffersen complète donc l'analyse en vérifiant l'indépendance des exceptions.

On considère les transitions entre deux indicateurs successifs. On note :

$$n_{ij} = \#\{t : I_{t-1} = i, I_t = j\}, \quad i, j \in \{0, 1\}.$$

On obtient ainsi les quatre nombres

$$n_{00}, \quad n_{01}, \quad n_{10}, \quad n_{11}.$$

On estime ensuite les probabilités de transition par maximum de vraisemblance :

$$\hat{\pi}_0 = \frac{n_{01}}{n_{00} + n_{01}},$$

et

$$\hat{\pi}_1 = \frac{n_{11}}{n_{10} + n_{11}}.$$

Sous l'hypothèse d'indépendance,

$$H_0 : \pi_0 = \pi_1 = \pi,$$

avec

$$\hat{\pi} = \frac{n_{01} + n_{11}}{n_{00} + n_{01} + n_{10} + n_{11}}.$$

La vraisemblance sous l'hypothèse d'indépendance est

$$L_0 = (1 - \hat{\pi})^{n_{00} + n_{10}} \hat{\pi}^{n_{01} + n_{11}},$$

tandis que la vraisemblance du modèle alternatif est

$$L_1 = (1 - \hat{\pi}_0)^{n_{00}} \hat{\pi}_0^{n_{01}} (1 - \hat{\pi}_1)^{n_{10}} \hat{\pi}_1^{n_{11}}.$$

La statistique de test est

$$\text{LR}_{IND} = -2 \log \left(\frac{L_0}{L_1} \right),$$

qui suit asymptotiquement une loi

$$\chi_1^2.$$

Une p-value inférieure à 5 % indique donc que les exceptions ne peuvent pas être considérées comme indépendantes.

5.4 Test de couverture conditionnelle

Une VaR satisfaisante doit satisfaire simultanément deux propriétés : le nombre d'exceptions doit être correct et celles-ci doivent être indépendantes.

Le test de couverture conditionnelle de Christoffersen combine donc les deux composantes :

$$LR_{CC} = LR_{UC} + LR_{IND}.$$

Sous l'hypothèse de couverture conditionnelle correcte,

$$LR_{CC} \stackrel{a}{\sim} \chi_2^2.$$

Le test constitue ainsi le critère principal retenu dans cette étude pour juger de la qualité globale d'une méthode de VaR.

6 Résultats du backtesting

Les quatre méthodes sont évaluées sur les mêmes 1431 observations, avec la même fenêtre glissante de 750 jours et les mêmes niveaux de confiance.

Les résultats sont présentés dans le tableau suivant. Les valeurs indiquées correspondent aux p-values des différents tests.

Méthode	Niveau	Exceptions	Taux	Kupiec	Christoffersen	Couverture conditionnelle
Historique	95 %	71	4.96 %	0.9467	0.2030	0.4437
Historique	99 %	11	0.77 %	0.3593	0.0020	0.0056
Normale	95 %	49	3.42 %	0.0038	0.3385	0.0096
Normale	99 %	20	1.40 %	0.1538	0.0295	0.0338
Monte Carlo	95 %	50	3.49 %	0.0058	0.3701	0.0150
Monte Carlo	99 %	20	1.40 %	0.1538	0.0295	0.0338
KDE	95 %	63	4.40 %	0.2902	0.2049	0.2559
KDE	99 %	10	0.70 %	0.2260	0.0564	0.0778

TABLE 3 – Résultats du backtesting des différentes méthodes de VaR

La règle de décision est la suivante : une p-value supérieure à 5 % conduit à ne pas rejeter l'hypothèse nulle du test considéré. Cela ne signifie pas que l'hypothèse nulle est démontrée, mais simplement que les données disponibles ne fournissent pas suffisamment d'éléments pour la rejeter.

6.1 VaR historique

À 95 %, la méthode historique produit 71 exceptions sur 1431 observations, soit

$$\frac{71}{1431} \simeq 4.96 \%.$$

Cette fréquence est extrêmement proche des 5 % attendus. Le test de Kupiec fournit une p-value de 0.9467, tandis que les tests de Christoffersen et de couverture conditionnelle donnent respectivement 0.2030 et 0.4437.

La méthode historique satisfait donc les trois tests à 95 %.

À 99 %, seulement 11 exceptions sont observées, soit 0.77 %. La couverture inconditionnelle reste compatible avec le niveau théorique puisque la p-value de Kupiec vaut 0.3593.

En revanche, le test d'indépendance est rejeté :

$$p_{\text{Christoffersen}} = 0.0020.$$

La couverture conditionnelle est également rejetée avec une p-value de 0.0056.

La méthode historique reproduit donc correctement la fréquence moyenne des événements extrêmes à 99 %, mais les exceptions ne sont pas suffisamment indépendantes dans le temps.

6.2 VaR paramétrique normale

À 95 %, la méthode normale produit 49 exceptions, soit seulement

$$3.42 \, \%.$$

Cette fréquence est significativement inférieure aux 5 % attendus. Le test de Kupiec conduit donc à rejeter la couverture correcte :

$$p = 0.0038.$$

La VaR normale apparaît ainsi trop élevée dans le cadre de cet échantillon : les dépassements sont moins nombreux que prévu.

Le test de Christoffersen n'est quant à lui pas rejeté, avec une p-value de 0.3385. Toutefois, la couverture conditionnelle est rejetée :

$$p = 0.0096.$$

À 99 %, 20 exceptions sont observées, soit 1.40 %. La couverture inconditionnelle n'est alors pas rejetée, avec une p-value de 0.1538.

Cependant, le test d'indépendance est rejeté :

$$p = 0.0295,$$

ce qui conduit également au rejet de la couverture conditionnelle :

$$p = 0.0338.$$

La méthode normale ne parvient donc pas à satisfaire simultanément les critères de fréquence et d'indépendance.

6.3 Simulation de Monte Carlo

Les résultats obtenus par Monte Carlo sont très proches de ceux de l'approche normale. À 95 %, on obtient 50 exceptions, soit 3.49 %, avec une p-value de Kupiec égale à 0.0058. La couverture inconditionnelle est donc rejetée.

À 99 %, 20 exceptions sont obtenues, soit 1.40 %. Comme pour la méthode normale, le test de Kupiec n'est pas rejeté, mais le test de Christoffersen l'est.

Cette proximité entre les deux méthodes est cohérente avec leur construction. Le Monte Carlo utilisé ici simule en effet des pertes à partir de la loi normale calibrée sur les données. Il n'introduit donc pas une nouvelle hypothèse de distribution.

Le recours à la simulation ne permet ainsi pas, dans cette application, de résoudre le problème lié à la non-normalité des pertes.

6.4 VaR obtenue par KDE

La méthode KDE donne les résultats les plus satisfaisants.

À 95 %, elle produit 63 exceptions sur 1431 observations, soit

$$4.40 \, \%.$$

Les trois tests sont validés :

$$p_{UC} = 0.2902,$$

$$p_{IND} = 0.2049,$$

et

$$p_{CC} = 0.2559.$$

À 99 %, 10 exceptions sont observées, soit 0.70 %. La couverture inconditionnelle n'est pas rejetée :

$$p_{UC} = 0.2260.$$

Le test d'indépendance fournit une p-value de

$$0.0564,$$

qui demeure supérieure au seuil de 5 %, mais de manière relativement marginale. La couverture conditionnelle est également validée avec

$$p_{CC} = 0.0778.$$

Il convient donc de considérer le résultat à 99 % avec davantage de prudence que celui obtenu à 95 %.

7 Comparaison des méthodes

Les résultats permettent de distinguer clairement les comportements des quatre approches.

À 95 %, deux méthodes satisfont les trois tests : la méthode historique et la KDE. La méthode normale et Monte Carlo produisent quant à elles trop peu d'exceptions. Elles conduisent donc à des niveaux de VaR relativement conservateurs dans cet échantillon.

À 99 %, la différence devient plus nette. La méthode KDE est la seule à satisfaire simultanément les tests de couverture inconditionnelle, d'indépendance et de couverture conditionnelle. La méthode historique reproduit correctement la fréquence globale des exceptions mais échoue sur leur indépendance. Les approches normale et Monte Carlo échouent également sur l'indépendance.

Ces résultats peuvent être rapprochés des propriétés descriptives des données. La distribution des pertes présente une kurtosis excédentaire de plus de 12, ce qui témoigne de queues épaisses. L'hypothèse normale apparaît donc particulièrement restrictive.

La méthode historique évite cette hypothèse mais demeure directement dépendante des observations disponibles. La KDE conserve également l'information historique tout en produisant une distribution continue et lissée. Cette flexibilité supplémentaire semble être bénéfique dans le cadre de l'échantillon étudié.

Il serait cependant excessif d'en déduire que la KDE constitue une méthode universellement supérieure. Les performances d'une méthode de VaR dépendent notamment de la période étudiée, de la fenêtre retenue, du comportement des marchés et des hypothèses de modélisation.

La conclusion pertinente est donc plus précisément la suivante :

Dans le cadre de notre échantillon et du protocole de backtesting retenu, la VaR obtenue par estimation de densité par noyau présente les résultats de validation les plus satisfaisants. Elle est la seule méthode à ne rejeter aucun des trois tests considérés aux niveaux de confiance de 95 % et 99 %.

Le résultat à 99 % doit néanmoins être interprété avec prudence, puisque la p-value du test de Christoffersen, égale à 0.0564, est relativement proche du seuil de 5 %.

8 Limites de l'étude

Plusieurs limites doivent être prises en compte dans l'interprétation des résultats.

8.1 Taille effective de la queue

La première limite concerne les niveaux de confiance élevés. Avec une fenêtre de 750 observations, une VaR à 99 % repose sur une zone correspondant théoriquement à seulement 7.5 observations extrêmes.

L'estimation d'un quantile situé dans une telle région est nécessairement plus incertaine que l'estimation d'un quantile à 95 %.

Cette difficulté concerne particulièrement la KDE : le choix du bandwidth influence directement la forme de la queue estimée.

8.2 Choix de la fenêtre

La fenêtre de 750 jours constitue un compromis entre stabilité statistique et adaptation aux changements de régime. Un autre choix pourrait modifier les résultats.

Une analyse complémentaire pourrait consister à comparer plusieurs fenêtres, par exemple 500, 750 et 1000 observations, afin d'étudier la robustesse des conclusions.

8.3 Hypothèse de normalité

Les méthodes normale et Monte Carlo utilisées ici reposent sur une hypothèse gaussienne. Cette hypothèse apparaît discutable compte tenu de la forte kurtosis observée.

Une extension naturelle consisterait à utiliser une loi à queues plus épaisses, par exemple une loi de Student, ou un modèle dynamique de volatilité.

8.4 Indépendance temporelle des rendements

Les méthodes présentées ne modélisent pas explicitement une dynamique temporelle de la volatilité. Or, les marchés financiers présentent généralement des phénomènes de regroupement de volatilité (*volatility clustering*).

Une extension pourrait donc consister à utiliser un modèle GARCH ou une approche à volatilité conditionnelle.

8.5 Limites des tests de backtesting

Les tests statistiques ne permettent pas de démontrer qu'une méthode est correcte. Ils permettent seulement de déterminer si les données disponibles fournissent suffisamment d'éléments pour rejeter certaines hypothèses.

Cette distinction est particulièrement importante à 99 %, où le nombre d'événements extrêmes observés reste faible.

9 Conclusion

Ce travail avait pour objectif de comparer plusieurs méthodes de mesure de la Value-at-Risk et d'évaluer leur capacité à prévoir les pertes extrêmes d'un portefeuille diversifié.

Le portefeuille étudié est composé de cinq ETF équipondérés représentant différentes classes d'actifs. À partir de leurs rendements quotidiens, quatre méthodes de VaR ont été étudiées : la méthode historique, l'approche paramétrique normale, la simulation de Monte Carlo et l'estimation non paramétrique par noyau.

Le choix d'une fenêtre glissante de 750 observations permet de construire des prévisions dynamiques tout en conservant un nombre suffisamment important d'observations pour estimer les quantiles. Les niveaux de confiance de 95 % et 99 % permettent quant à eux d'étudier à la fois le risque courant et les pertes plus extrêmes.

Les résultats mettent en évidence les limites de l'hypothèse normale. La distribution observée des pertes présente en effet une forte kurtosis et une asymétrie positive. Les méthodes normale

et Monte Carlo donnent ainsi des résultats relativement conservateurs à 95 % et ne satisfont pas les tests de couverture conditionnelle.

La méthode historique donne de bons résultats à 95 %, mais son comportement à 99 % révèle une dépendance temporelle des exceptions. La KDE présente quant à elle les résultats les plus satisfaisants sur l'ensemble des critères considérés : elle ne conduit au rejet d'aucun des trois tests, aussi bien à 95 % qu'à 99 %.

Cette performance peut s'expliquer par sa position intermédiaire entre deux approches. Contrairement à la méthode paramétrique normale, elle ne contraint pas la distribution à une forme gaussienne. Contrairement à la méthode historique, elle produit une distribution continue et lissée, ce qui permet d'obtenir une estimation plus flexible des quantiles.

La conclusion doit néanmoins rester spécifique au cadre de l'étude. La KDE ne peut pas être considérée comme universellement supérieure à toutes les autres méthodes de VaR. Ses performances dépendent notamment du choix du bandwidth, de la fenêtre historique et de la qualité des données disponibles. Le résultat à 99 % est en particulier moins robuste, puisque le test d'indépendance est proche du seuil de rejet.

Ainsi, dans le cadre de l'échantillon et du protocole de backtesting retenus, l'estimation non paramétrique par noyau apparaît comme la méthode fournissant les prévisions de VaR les plus satisfaisantes. Une extension naturelle serait de tester la robustesse de cette conclusion sur plusieurs fenêtres d'estimation et plusieurs périodes de marché, ainsi que de comparer la KDE à des modèles capables de prendre explicitement en compte la dynamique de la volatilité.